

Arquitetura Multiagente com CNN para Triagem Automatizada de Pneumonia

Vinicius Carvalho Miranda

Universidade de Rio Verde (UniRV)

vncs2012@gmail.com

Resumo

Este trabalho apresenta o **AgentTriagem**, um sistema híbrido que integra Redes Neurais Convolucionais (CNN) a uma arquitetura multiagente para triagem médica automatizada. O sistema utiliza a arquitetura **DenseNet121** para detecção de pneumonia em imagens de raio-X torácico, empregando o conjunto de dados *Chest X-Ray Images (Pneumonia)*, disponibilizado no Kaggle. A orquestração do fluxo de triagem é realizada por meio do **Agent Development Kit (ADK)** da Google, utilizando o **Model Context Protocol (MCP)** para garantir interoperabilidade entre fontes de dados e agentes inteligentes. Os resultados experimentais indicam acurácia de **88,3%** e **AUC de 0,96**, demonstrando que a solução é eficaz como ferramenta de apoio à decisão clínica em ambientes hospitalares de alta demanda.

Palavras-chave: Triagem médica; Redes neurais convolucionais; Sistemas multiagente; Pneumonia; Inteligência artificial em saúde.

Abstract

This paper presents **AgentTriagem**, a hybrid system that integrates Convolutional Neural Networks (CNN) with a multi-agent architecture for automated medical triage. The system employs the **DenseNet121** architecture for pneumonia detection in chest X-ray images, using the *Chest X-Ray Images (Pneumonia)* dataset made publicly available on Kaggle. The triage workflow is orchestrated through Google's **Agent Development Kit (ADK)**, while data interoperability among agents and external systems is ensured by the **Model Context Protocol (MCP)**. Experimental results show an accuracy of **88.3%** and an **AUC of 0.96**, indicating that the proposed solution is effective as a clinical decision-support tool in high-demand hospital environments.

Keywords: Medical triage; Convolutional neural networks; Multi-agent systems; Pneumonia; Artificial intelligence in healthcare.

1. Introdução

A pneumonia permanece como uma das principais causas de mortalidade em nível global, exigindo diagnósticos rápidos e precisos para redução de complicações graves [2]. Em unidades de emergência, a elevada demanda por atendimentos e a escassez de especialistas podem atrasar a análise de radiografias torácicas, impactando negativamente o prognóstico dos pacientes.

Embora modelos de *Deep Learning* tenham apresentado avanços significativos na classificação de imagens médicas, grande parte dessas soluções opera de forma isolada, sem integração aos fluxos clínicos e sistemas hospitalares. Nesse contexto, este trabalho propõe o **AgentTriagem**, uma solução que combina a capacidade diagnóstica da arquitetura **DenseNet121** [1] com a flexibilidade de **Sistemas Multiagente**, permitindo automatizar não apenas a

inferência, mas todo o processo de triagem, desde a consulta a bases de dados até a notificação médica, utilizando o **ADK** e o **MCP** [3][4].

2. Trabalhos Relacionados

Diversos estudos demonstram que arquiteturas baseadas em CNN apresentam desempenho comparável ou superior ao de especialistas humanos na detecção de patologias pulmonares em imagens de raio-X, especialmente no que se refere à velocidade de análise [2][5]. Entretanto, pesquisas recentes apontam que a eficácia clínica desses modelos depende fortemente de sua integração aos sistemas de informação em saúde.

Nesse cenário, protocolos de interoperabilidade como o **Model Context Protocol (MCP)**, proposto em 2024, surgem como uma solução padronizada para conectar modelos de IA a diferentes fontes de dados de forma segura e estruturada [3]. O **AgentTriagem** diferencia-se dos trabalhos existentes ao aplicar essa interoperabilidade no contexto específico da triagem de pneumonia, utilizando uma arquitetura multiagente orquestrada pelo **ADK** [4].

3. Metodologia

3.1 Arquitetura do Sistema e Orquestração

O sistema adota uma arquitetura multiagente hierárquica implementada sobre o **Agent Development Kit (ADK)**. Um agente orquestrador central é responsável por coordenar o fluxo da triagem, delegando tarefas a agentes especializados em diagnóstico, obtenção de contexto clínico e notificação médica. Essa abordagem permite modularidade, escalabilidade e fácil manutenção do sistema [4].

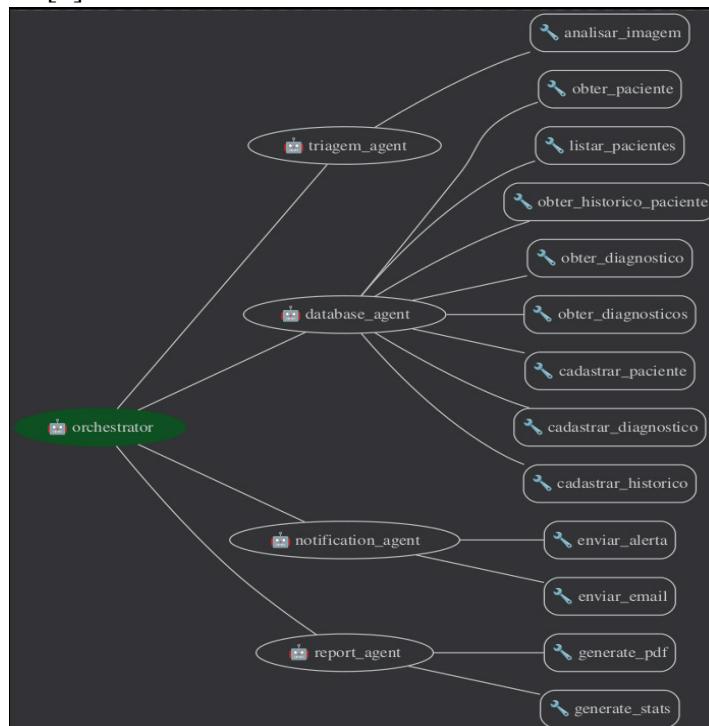


Figura 1.Estrutura dos agentes e ferramentas do sistema.

3.2 Desenvolvimento do Modelo de Machine Learning

O modelo de classificação utiliza a arquitetura **DenseNet121**, escolhida por sua eficiência no reaproveitamento de características e redução do número de parâmetros [1]. Foi empregada a técnica de *Transfer Learning*, com pesos pré-treinados no conjunto **ImageNet**. As imagens foram redimensionadas para **224 × 224 pixels** e normalizadas conforme os padrões da arquitetura adotada.

3.3 Base de Dados

O treinamento e a avaliação do modelo utilizaram o dataset **Chest X-Ray Images (Pneumonia)**, disponível publicamente no Kaggle [6]. O conjunto contém **5.856 imagens** de radiografias torácicas, provenientes de coortes retrospectivas do *Guangzhou Women and Children's Medical Center*, amplamente utilizadas na literatura científica [2].

3.4 Model Context Protocol (MCP)

A integração entre agentes e fontes de dados é realizada por meio do **Model Context Protocol (MCP)**, que permite a comunicação padronizada com sistemas externos, como bancos de imagens DICOM e prontuários eletrônicos, utilizando mensagens estruturadas no formato **JSON-RPC 2.0** [3].

4. Resultados e Avaliação

O modelo foi avaliado em um conjunto de teste independente composto por **624 imagens**. Os resultados obtidos estão apresentados na Tabela 1.

Métrica	Classe Normal	Classe Pneumonia	Global
Precisão	0,90	0,88	–
Recall (Sensibilidade)	0,78	0,95	–
F1-Score	0,84	0,91	–
Acurácia / AUC	–	–	88,3% / 0,96

A elevada sensibilidade observada para a classe pneumonia (0,95) é particularmente relevante em cenários de triagem hospitalar, pois reduz a probabilidade de falsos negativos em casos críticos [2].

5. Conclusão

Os resultados demonstram que o **AgentTriagem** é uma solução viável e promissora para triagem médica automatizada. A integração de modelos de visão computacional com arquiteturas multiagente interoperáveis possibilita não apenas a detecção de doenças, mas também a orquestração inteligente do fluxo de cuidado ao paciente. O uso do **MCP** e do **ADK** estabelece uma base sólida para futuras expansões do sistema em ambientes clínicos reais.

Referências Bibliográficas

- [1] HUANG, G.; LIU, Z.; VAN DER MAATEN, L.; WEINBERGER, K. Q. *Densely Connected Convolutional Networks*. In: **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)**, 2017.
- [2] KERMANI, D. S. et al. *Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning*. **Cell**, v. 172, n. 5, p. 1122–1131, 2018.
- [3] ANTHROPIC. *Model Context Protocol (MCP): Specification and Open Standard*. Anthropic Engineering, 2024.
- [4] GOOGLE CLOUD. *Agent Development Kit (ADK): Framework for AI Agents*. Google Developers, 2025.
- [5] KUNDU, R. et al. *Pneumonia detection in chest X-ray images using an ensemble of deep learning models*. **PLOS ONE**, v. 16, n. 9, 2021.
- [6] MOONEY, P. T. *Chest X-Ray Images (Pneumonia)*. Kaggle Dataset, 2018. Disponível em: <https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia>.